

Kiodai

Структурированная перспективная память языковых ИИ-агентов и методика её оценки

Беймжан Багдат, 10 класс

Назарбаев Интеллектуальная школа естественно-математического
направления района Нура города Астаны

Руководитель: Омаров Абылайхан Бауржанович

Когда появится нужное условие, выполни ранее заданное поручение.




Схема задачи

Исследовательский вопрос и гипотеза

Вспомнить поручение

Выполнить его вовремя

Помогает ли явная поддержка намерений действовать вовремя по сравнению с тем же агентом без такой поддержки?

Гипотеза: условия, действия и состояния в явном виде повысят качество.

Структурированное хранение уже исследуется в PIS.
Сама идея хранения не заявляется как новая.

Что построено и с чем сравнивается

Исторические пилоты A1

Дополнение к инструкции

A0 = A1: 1,00

Позднее: $\approx 0,9565$

Больше входных токенов

Финальное сравнение

A0

История и разрешённые инструменты

Общие извлечение, хранилище, версии
и обработка подтверждений:

B_ledger

Запросами управляет модель

A2

Запросами управляет
ограниченный контроллер

Дизайн эксперимента

12

траекторий

4

семейства шаблонов

3

метода

События, скрытые условия, другой день, изменения поручений

DeepSeek V3.1 через OpenRouter / Novita


36 запусков методов, 288 контрольных точек, 602 вызова

Set-F1 учитывает правильные действия, пропуски и лишние действия.

Сценарии разработки; один запуск на условие.

В этом сравнении A0 получил наивысший результат

Средний Set-F1 по траекториям



A2 – B_ledger $\approx -0,3306$


Основная разность

A2 – A0 $\approx -0,3837$

Вторичная разность

Дополнительные вычисления не дали улучшения в этой серии

Записанная стоимость API, USD




$A2 / A0 \approx 4,91$ раза

Стоимость этой серии по API. Не текущие тарифы и не затраты разработки.

После замены условия вернулся старый триггер


Поручение: запечатать контейнер при новом сигнале «треугольник».



Точка 5: условие восстановлено. Ранняя ошибка осталась в оценке.

Локальная ошибка обновления и действия. Причина общего отставания не установлена.

Где может возникнуть ошибка



Наблюдается в журналах

Старое условие вернулось в запись.
Положительный ответ скрытого канала
получен, но действие не выполнено.

Возможное объяснение

Ошибочная интерпретация
может влиять на следующие
решения. Вклад не
изолирован.

**Наличие сохранённой информации само по себе
не обеспечило правильного действия.**

Ограничения и фактический вклад

Установлено

Система реализована и сравнена.
У A2 самый низкий основной балл.
В журналах есть конкретные сбои.

Не установлено

Перенос на другие модели и практику.
Результат на закрытой выборке.
Причинный вклад каждого этапа.
Успешность исправления.

4 семейства, 1 запуск на условие, известные сценарии,
неравные вычисления, разбор ошибок с ИИ-помощью.

**Вклад автора: вопрос и методика сравнения.
Код и текст подготовлены с ИИ-помощью.**

Проверенная A2 не улучшила основную метрику

Гипотеза об улучшении не получила поддержки в проверенных условиях.

Следующий вопрос

Какая часть потерь возникает при построении и обновлении намерений, а какая при исполнении?

Предложение: диагностика с эталонным состоянием только из доступной к шагу информации. Ещё не проведена.

Метрики и полные результаты

Метод	Среднее Set-F1	Micro Set-F1	TP	FP	FN	ВЫЗОВЫ	API, USD
A0	0,8643	0,8462	22	6	2	117	0,04047
B_ledger	0,8111	0,8372	18	4	3	251	0,21212
A2	0,4806	0,6667	12	5	7	234	0,19871

Set-F1 = 2TP / (2TP + FP + FN)

TP: верное действие. FP: лишнее. FN: пропущенное.

Среднее: равный вес каждой траектории. Micro: сначала сумма TP, FP, FN.
Суммарные счётчики не восстанавливают распределение оценок по траекториям.

Валидность сравнения

Парные условия	Одинаковые стартовые инструкции, инструменты и 8 точек. У каждого метода своё состояние и последующая история.
Экспозиция	Все 12 сценариев известны при разработке. Одна траектория также использовалась в сетевой smoke-проверке.
Фиксация	Конфигурация, промпты и сценарии заморожены до запуска. Итоговый отчёт фиксирует завершение и сохранение ошибок.
Граница оценивания	Эталонные ответы остаются на стороне оценщика. Невалидный ответ после повтора даёт отсутствие действия.

**288 точек и 602 вызова принадлежат тем же траекториям.
Это нагрузка, а не независимые повторения.**

Диагностика и её ограничения

Счётчик	A0	B_ledger	A2
Запросы скрытого канала	15	8	18
Успехи с опорой на запрос	6	4	3
Ошибки проверки выбора	2	24	15

Больше запросов не означает больше успешных действий.
Ошибки проверки не равны числу ошибочных намерений.

**Учёт уточнён: 27 поручений = 24 завершённых
или незавершённых без отменённых + 3 отменённых.**

Три отмены подтверждены в сценариях revision. Этот баланс не заменяет Set-F1.

Источники, авторство и воспроизводимость

Предшествующие работы

Liu G., Gabriel S. PM-Bench (2026)
Постановка задачи, среда и Set-F1
arXiv:2607.12385v1

Zhao J., Wu C. Typed Intention Stores (2026)
PIS: типизированные намерения и жизненный цикл
arXiv:2609.01272v1

Zhang T. et al. TriggerBench (2026)
Проверка условий срабатывания
arXiv:2606.23459v1

Автор и доступные материалы

Вопрос и методика сравнения.
ИИ помогал с кодом, текстом
и разбором ошибок.

Локально сохранены код,
промпы, конфигурации,
запросы, ответы и оценки.

**Код сам по себе не доказывает
самостоятельность и корректность.**