

Kiodai

Структурированная перспективная память языковых ИИ-агентов и методика её оценки

Беймжан Багдат, 10 класс

Назарбаев Интеллектуальная школа
естественно-математического направления района Нура
города Астаны

Руководитель:
Омаров
Абылайхан Бауржанович

Когда появится нужное условие, выполни ранее заданное поручение.




Схема задачи

Исследовательский вопрос и гипотеза

Вспомнить поручение

Выполнить его вовремя

Помогает ли явная поддержка намерений действовать вовремя по сравнению с тем же агентом без такой поддержки?

Гипотеза: условия, действия и состояния в явном виде повысят качество.

Структурированное хранение уже исследуется в PIS.
Сама идея хранения не заявляется как новая.

Что построено и с чем сравнивается

03

Исторические пилоты A1

Дополнение к инструкции

A0 = A1: 1,00

Позднее: $\approx 0,9565$

Больше входных токенов

Финальное сравнение

A0

История и разрешённые инструменты

Общие извлечение, хранилище, версии
и обработка подтверждений:

B_ledger

Запросами управляет модель

A2

Контроллер проверяет до одного
канала за шаг, начиная с давно
не проверявшегося.

12

траекторий

4

семейства шаблонов

3

метода

События, скрытые условия, другой день, изменения поручений

DeepSeek V3.1
через OpenRouter / Novita


Set-F1 учитывает правильные действия,
пропуски и лишние действия.

36 запусков методов,
288 контрольных точек, 602 вызова

Сценарии разработки;
один запуск на условие.

В этом сравнении A0 получил наивысший результат

Средний Set-F1 по траекториям



Основная разность

$A2 - B_ledger \approx$

-0,3306


Вторичная разность

$A2 - A0 \approx$

-0,3837

Дополнительные вычисления не дали улучшения в этой серии

Записанная стоимость API, USD



$A2 / A0 \approx$


4,91

раза

Стоимость этой серии по API. Не текущие тарифы и не затраты разработки.

После замены условия вернулся старый триггер

Поручение: запечатать контейнер при новом сигнале «треугольник».




Точка 5: условие восстановлено. Ранняя ошибка осталась в оценке.

Локальная ошибка обновления и действия.

Причина общего отставания не установлена.

Где может возникнуть ошибка

08



Наблюдается в журналах

Старое условие вернулось в запись.
Положительный ответ скрытого канала
получен, но действие не выполнено.

Возможное объяснение

Ошибочная интерпретация
может влиять на следующие
решения. Вклад не изолирован.

Наличие сохранённой информации само по себе
не обеспечило правильного действия.

Установлено

Система реализована и сравнена.
У A2 самый низкий основной балл.
В журналах есть конкретные сбои.

Не установлено

Перенос на другие модели и практику.
Результат на закрытой выборке.
Причинный вклад каждого этапа.
Успешность исправления.

4 семейства, 1 запуск на условие, известные сценарии,
неравные вычисления, разбор ошибок с ИИ-помощью.

Вклад автора: постановка эксперимента, организация разработки,
запуска сравнения и анализа результатов с ИИ-помощью.

Проверенная A2 не улучшила основную метрику

Гипотеза об улучшении не получила поддержки в проверенных условиях.

Следующий вопрос

Какая часть потерь возникает при построении и обновлении намерений, а какая при исполнении?

Предложение: диагностика с эталонным состоянием только из доступной к шагу информации. Ещё не проведена.

Метрики и полные результаты

Метод	Среднее Set-F1	Micro Set-F1	TP	FP	FN	Вызовы	API, USD
A0	0,8643	0,8462	22	6	2	117	0,04047
B_ledger	0,8111	0,8372	18	4	3	251	0,21212
A2	0,4806	0,6667	12	5	7	234	0,19871

$$\text{Set-F1} = 2TP / (2TP + FP + FN)$$

TP: верное действие. FP: лишнее. FN: пропущенное.

Среднее: равный вес каждой траектории. Micro: сначала сумма TP, FP, FN.
Суммарные счётчики не восстанавливают распределение оценок по траекториям.

Источник: COMPARISON_RESULTS, Primary results и Resources; все 12 траекторий

Валидность сравнения

Парные условия	Одинаковые стартовые инструкции, инструменты и 8 точек. У каждого метода своё состояние и последующая история.
Экспозиция	Все 12 сценариев известны при разработке. Одна траектория также использовалась в сетевой smoke-проверке.
Фиксация	Конфигурация, промпты и сценарии заморожены до запуска. Итоговый отчёт фиксирует завершение и сохранение ошибок.
Граница оценивания	Эталонные ответы остаются на стороне оценщика. Невалидный ответ после повтора даёт отсутствие действия.

288 точек и 602 вызова принадлежат тем же траекториям.
Это нагрузка, а не независимые повторения.

Диагностика и её ограничения

Счётчик	A0	B_ledger	A2
Запросы скрытого канала	15	8	18
Успехи с опорой на запрос	6	4	3
Ошибки проверки выбора	2	24	15

Больше запросов не означает больше успешных действий.
Ошибки проверки не равны числу ошибочных намерений.

Учёт уточнён: 27 поручений = 24 завершённых
или незавершённых без отменённых + 3 отменённых.

Три отмены подтверждены в сценариях revision. Этот баланс не заменяет Set-F1.

Источники: статья, § 5.3; comparison-v1, сценарии revision; semantic_review.json

Источники, авторство и воспроизводимость

Предшествующие работы

Liu G., Gabriel S. PM-Bench (2026)

Постановка задачи, среда и Set-F1

[arXiv:2607.12385v1](#)

Zhao J., Wu C. Typed Intention Stores (2026)

PIS: типизированные намерения и жизненный цикл

[arXiv:2609.01272v1](#)

Zhang T. et al. TriggerBench (2026)

Проверка условий срабатывания

[arXiv:2606.23459v1](#)

Автор и доступные материалы

Вопрос и методика сравнения.
ИИ помогал с кодом, текстом
и разбором ошибок.

Локально сохранены код,
промнты, конфигурации,
запросы, ответы и оценки.