

Назарбаев Интеллектуальная школа
естественно-математического направления
района Нура города Астаны

НАУЧНЫЙ ПРОЕКТ

**Kiodai: структурированная перспективная
память языковых ИИ-агентов и методика её
оценки**

Направление II
«Математическое моделирование экономических
и социальных процессов»
Секция: информатика

Автор: Беймжан Багдат / Bagdat Beimzhan
Ученик 10 класса

Научный руководитель:
Омаров Абылайхан Бауржанович

Астана, 2026

ОГЛАВЛЕНИЕ

Аңдатпа.....	3
Аннотация.....	3
Abstract.....	3
1. Введение.....	4
2. Теоретические основы и связанные работы.....	4
2.1. От воспоминания к выполнению намерения.....	4
2.2. Близкие оценки памяти и структурированные хранилища.....	5
3. Системы и реализация.....	5
3.1. Исторические и итоговые условия.....	5
3.2. Путь от инструкции до подтверждения.....	6
4. Экспериментальная методика.....	7
4.1. Сценарии, фиксация и условия запуска.....	7
4.2. Оценщик, ошибки и единица анализа.....	8
5. Результаты.....	9
5.1. Пилоты и проверка работоспособности.....	9
5.2. Основное сравнение.....	10
5.3. Ресурсы и учёт обязательств.....	10
6. Анализ ошибок и обсуждение.....	12
6.1. Наблюдаемые стадии отказа.....	12
6.2. Разбор цепочки и возможное объяснение.....	13
7. Ограничения, практическая значимость и вклад автора.....	13
8. Заключение.....	14
9. Список использованных источников.....	16

Аңдатпа

Мақсат: тілдік ЖИ-агенттің перспективалық жадын, яғни ниетті уақтылы орындауын бағалау. Алғашқы гипотеза тұрақты Kiodai нұсқаулығы нәтижені жақсартады деп болжады; кейін ол айқын ниеттер қоймасы мен бақылау тетіктерін тексеруге кеңейтілді. Бірінші кезеңдегі A0/A1 пилоттарында жақсару байқалмады. Екінші кезеңде DeepSeek V3.1 моделінің A0, B_ledger және A2 нұсқалары төрт үлгі отбасынан алынған 12 траекторияда салыстырылды: әр жұпқа бір іске қосу. Сценарийлер әзірлеу кезінде қолжетімді болды. Негізгі көрсеткіш: траекториялар бойынша Set-F1 орташа мәні. A0, B_ledger және A2 үшін ол тиісінше 0,8643; 0,8111; 0,4806 болды. Негізгі A2 – B_ledger айырмасы –0,330556 құрады. Жақсару гипотезасы осы жағдайда қолдау таппады. Жобаның үлесі: жұмыс істейтін жүйені іске асыру, бекітілген салыстыру және жазбаларға сүйенген қателерді талдау. Ниеттер қоймасы идеясы бұрынғы еңбектерге негізделген. Авторлық бөлік зерттеу сұрағы мен салыстыру әдістемесін қамтиды; код, мәтін және мағыналық талдау ЖИ көмегімен дайындалды, тәуелсіз адам сарапшысының бағасы жоқ. Әдістеме оқу және ұйымдастыру көмекшілерін бағалауға ықтимал қолданылады; олардың нақты пайдасы тексерілмеді.

Аннотация

Цель: оценить перспективную память языкового ИИ-агента, то есть своевременное выполнение намерений. Первоначальная гипотеза предполагала пользу фиксированной инструкции Kiodai; позднее исследование расширилось до явного хранения намерений и средств контроля. В пилотах A0/A1 улучшения не наблюдалось. Затем A0, B_ledger и A2 на модели DeepSeek V3.1 сравнили на 12 траекториях четырёх семейств: один запуск на пару «метод–траектория». Сценарии были доступны при разработке. Основной показатель: среднее траекторное Set-F1. Для A0, B_ledger и A2 он составил соответственно 0,8643; 0,8111; 0,4806. Основная разность A2 – B_ledger равна –0,330556. Гипотеза улучшения в этих условиях не получила поддержки. Вклад проекта: реализация системы, зафиксированное сравнение и анализ ошибок по сохранённым записям. Идея хранилища намерений заимствована из предшествующих работ. Авторская часть включает исследовательский вопрос и методику сравнения; код, текст и семантический разбор подготовлены с помощью ИИ, независимого человека-разметчика не было. Методика потенциально применима к оценке учебных и организационных помощников; их практическая полезность не проверялась.

Abstract

This study evaluates prospective memory in language-model agents: executing earlier intentions at the appropriate moment. The initial hypothesis predicted benefits from a fixed Kiodai instruction; the investigation later expanded to explicit intention storage and control mechanisms. The A0/A1 pilots showed no improvement. A0, B_ledger, and A2 using DeepSeek V3.1 were then compared on 12 trajectories from four template families, with one run per method–trajectory pair. The scenarios were exposed during development. The primary measure, mean trajectory Set-F1, was 0.8643, 0.8111, and 0.4806, respectively. The primary A2 – B_ledger difference was –0.330556. The improvement hypothesis was not supported under these conditions. The contribution comprises an implemented system, a frozen comparison, and record-based failure analysis. Intention stores are prior work. The author's contribution covers the research question and comparison methodology; AI assisted coding, writing, and semantic review, without an independent human annotator. Potential applications include evaluating educational and organizational assistants; practical benefits were not tested.

1. Введение

Пользователь может поручить помощнику: «Когда состояние охлаждения на панели станет стабильным, архивируй отчёт». Между поручением и подходящим моментом появляются другие сообщения. Условие может измениться, поручение могут отменить, а его выполнение может зависеть от завершения другой задачи. Агенту нужно сохранить актуальную инструкцию, при необходимости запросить разрешённые сведения, выбрать действие и проверить результат исполнения. Одного воспроизведения исходного текста недостаточно.

Перспективная память означает выполнение ранее сформированного намерения при наступлении нужного времени или события. Ретроспективная память отвечает на вопрос о прошлом: например, какой срок был указан. Перспективная память требует применить это знание в подходящий момент без нового прямого напоминания. PM-Bench исследует такое поведение в текстовом симуляторе с текущей деятельностью, отложенными действиями и запросами состояния среды [1].

Практическая значимость вопроса связана с помощниками, которые работают со сроками, переносами и условными напоминаниями. Полезная система должна и выполнять нужные действия, и воздерживаться от преждевременных или отменённых. В настоящем проекте учебные и организационные ситуации служат мотивацией. Работа не измеряет успеваемость, удобство приложения или надёжность реального внедрения.

Объект исследования: поведение языкового агента в последовательности взаимодействий. Предмет: влияние инструкции, явного представления намерений и политики мониторинга на своевременный выбор действий. Цель: реализовать Kiodai и оценить его в контролируемом сравнении, сохранив ошибки и ограничения доказательств.

Исследование развивалось в два этапа. Сначала проверялось, улучшает ли фиксированная инструкция P1 работу того же агента: базовое условие A0 сравнивалось с A1. После пилотов без наблюдаемого улучшения появился отдельный архитектурный этап. В нём сравнивались A0, структурированный вариант B_ledger с запросами по решению модели и A2 с ограниченным программным мониторингом. Расширение не было исходным планом A0/A1 и зафиксировано отдельным протоколом.

Исследовательские вопросы: помогает ли добавленная инструкция в пилотах; даёт ли A2 положительное среднее изменение Set-F1 относительно B_ledger; как качество связано с затратами и наблюдаемыми сбоями? Первоначально ожидалось улучшение от инструкции, позднее от архитектурного расширения. Методы работы: анализ литературы, реализация симуляторного агента, локальные проверки, парное сравнение и разбор сохранённых журналов. Выводы ограничены реализованной системой, одной конфигурацией модели и использованными сценариями.

2. Теоретические основы и связанные работы

2.1. От воспоминания к выполнению намерения

В парадигме Virtual Week отложенные поручения включены в моделируемую повседневную деятельность. Работа Rendell и Craik рассматривает выполнение намерений в лабораторной настольной игре и в повседневной жизни [2]. Для Kiodai важен принцип сочетания текущей деятельности с будущими обязательствами. Эксперимент над

языковым агентом при этом не является исследованием человеческой памяти и не позволяет переносить на ИИ психологические объяснения.

PM-Bench адаптирует эту постановку к текстовому агенту. Участник получает историю, сцену, меню действий и доступные каналы состояния. Среди опубликованных условий уже есть todo-ledger, то есть список намерений, условий и статусов в контексте [1]. Kiodai использует существующие симулятор и оценщик, но его итоговое сравнение проведено на отдельно составленных сценариях разработки. Оно не является новым результатом на опубликованной финальной неделе PM-Bench.

2.2. Близкие оценки памяти и структурированные хранилища

TriggerBench проверяет своевременное вмешательство по ранее заданным ограничениям и сопоставляет его с ретроспективными вопросами. Положительные, отрицательные и перегруженные дополнительной задачей варианты помогают различать полезное действие и склонность напоминать всегда [3]. Это обосновывает внимание к ложным действиям и близким, но неподходящим сигналам. Метрики TriggerBench и его условия отличаются от Set-F1 в настоящей работе.

MemoryAgentBench, представленный в статье Hu, Wang и McAuley, оценивает точное извлечение, обучение во время взаимодействия, понимание длинного контекста и избирательное забывание [4]. Это более широкая постановка оценки памяти. Kiodai проверяет конкретную цепочку исполнения намерений и не заявляет, что охватывает все четыре способности.

Prospective Intention Store, PIS, переносит намерения в типизированное внешнее хранилище. Его описание разделяет формирование, пересмотр, фильтрацию и выбор действия; модель выполняет ограниченные языковые операции, а программные правила управляют частью жизненного цикла [5]. Эта работа служит прямым предшественником архитектурного этапа Kiodai. Реализация Kiodai реконструирует отдельные идеи PIS по статье; точное воспроизведение PIS и сопоставимость всех его настроек не установлены.

Хранилище намерений, контроль версий, планирование и разделение оценщика с агентом не объявляются изобретениями проекта. Конкретный вклад состоит в реализации, зафиксированном сравнении двух политик мониторинга при общем хранилище и прослеживаемом анализе сбоев. Числа из других публикаций не сравниваются с Kiodai как результаты одного эксперимента: модели, сценарии, объём вычислений и правила исполнения различаются.

3. Системы и реализация

3.1. Исторические и итоговые условия

A0 использует базовую инструкцию, историю собственного взаимодействия и разрешённые инструменты. A1, также обозначаемый P1 в исторических записях, добавляет фиксированную инструкцию перспективной памяти к тому же агенту. Внешнее хранилище в этих пилотах не добавлялось. A1 не входит в итоговую тройку методов.

В B_ledger и A2 модель извлекает намерения в структурированные записи. В проверенном коде у них общие Agent, Store, Gateway, схема извлечения и тексты инструкций. Оба метода поддерживают версии, зависимости, отмены, проверку привязки и изменение статуса по подтверждениям исполнения. Основное различие относится к

выбору запросов состояния: B_ledger поручает его модели, A2 использует программную политику [6].

Таблица 1. Сравнимые условия и общий функционал.

Свойство	A0	A1 / P1	B_ledger	A2
Этап проверки	Пилоты и итог	Только пилоты	Итог	Итог
История и инструменты	Доступны	Доступны	Доступны	Доступны
Дополнение P1	Нет	Есть	Не это условие	Не это условие
Хранилище намерений	Нет	Нет	Есть	Есть
Версии, зависимости, отмены в хранилище	Нет слоя	Нет слоя	Общий Store	Общий Store
Обновление хранилища по receipts	Нет хранилища	Нет хранилища	Есть	Есть
Решение о запросе в итоговом сравнении	Модель	Не участвует	Модель	Контроллер

Отсутствие отдельного хранилища у A0 не означает отсутствия информации о поручениях. В итоговом сравнении все методы получают доступную историю, текущее меню и сообщения о результатах собственных действий. После разных запросов и действий их истории закономерно расходятся. A0 может сделать дополнительный вызов после запроса, поэтому он не сводится к одному вызову модели на контрольную точку.

3.2. Путь от инструкции до подтверждения

Ранняя запись $I = (c, a, s, v)$, где c обозначает условие, a действие, s состояние, v версию, использовалась как аналитическая спецификация. Реальная запись поздней реализации шире: она содержит собственный идентификатор, тип и текст условия, день и время при наличии, канал, зависимости, цитаты из доступных наблюдений, статус, версию и сведения о попытке исполнения. Данные и события сохраняются в SQLite. Формальная полнота полей не гарантирует верного смысла [6].

На контрольной точке модель предлагает операции создания или изменения записей. Программа проверяет структуру, ссылки на наблюдения и допустимость операций. Неполностью определённое намерение может попасть в карантин, то есть временно исключиться из исполнения. После успешного извлечения контроллер A2 рассматривает каналы, связанные с допустимыми незавершёнными намерениями, и отдаёт приоритет давно не проверявшемуся каналу. За одну точку разрешён не более чем один запрос. Если время уже видно в сцене, дополнительный запрос часов для временного намерения не нужен.




Рисунок 1. Обработка намерения в B_ledger и A2. Общие этапы совпадают; выделенное разветвление показывает различие политики запросов. Оценщик использует отдельное состояние после выбора действий.

Далее модель сопоставляет текущее наблюдение с условием и привязывает выбранный идентификатор действия из меню к намерению и его версии. Программный допуск проверяет статус и зависимости, но не доказывает правильность смыслового соответствия, дня или события. Сохранённая строка «DayTwo, 11:00» сама по себе не гарантирует запрета действия в DayOne.

После выбора фиксируется попытка. Подтверждение исполнения, или receipt, сообщает результат симулятора. В хранилище успешное подтверждение переводит намерение в completed; неуспешное и неопределённое различаются. Это позволяет отделить выбор от завершения, но неверная привязка может связать результат с неподходящей записью. Политика отмены в коде и отказ от старого номера версии также не исключают возвращения старого условия в новой версии. Исполнение реальных внешних действий «ровно один раз» здесь не проверялось.

4. Экспериментальная методика

4.1. Сценарии, фиксация и условия запуска

Итоговый протокол v2.1-comparison-v1 включает 12 синтетических траекторий: по три варианта четырёх семейств. Семейство hidden требует запросить скрытое состояние; visible_events использует видимые сигналы и их изменения; cross_day переносит обязательство на другой день; revision включает переносы сроков и отмены. В каждой траектории восемь контрольных точек, в cross_day они распределены по двум дням. Все сценарии были доступны в разработке и МОСК-проверках; hidden_91320 пересекается с прежними smoke-запусками [6].

На каждой траектории один раз выполнены A0, B_ledger и A2: всего 36 запусков и 288 контрольных точек. Дополнительного повтора, исключений и выборочных перезапусков

не было. Порядок семейств и вариантов задан seed 20260910, порядок методов циклически меняется и сбалансирован по позициям. Контрольные точки заданы симулятором. Heartbeat отключён; A2 не получает дополнительных возможностей между точками и не демонстрирует автономную фоновую работу.

Реализация-кандидат зафиксирована коммитом 959db38dac8b68f63ecf79420dcd53bea2278cf2; запуск 11 сентября 2026 года выполнен из cd0ce89e10d036918d1af06e5f5f2140930a0981. Поддержка эксперимента имеет отдельную версию 832d6ff. Манифест сохраняет хеши 59 файлов исходного кода, конфигурации и сценариев. В архиве сохранены 445 исходных файлов запуска. Их хеши и официальные оценки повторно проверены при подготовке статьи [6, 7].

Таблица 2. Зафиксированные настройки итогового сравнения.

Параметр	Значение
Модель и API-идентификатор	DeepSeek V3.1; deepseek/deepseek-chat-v3.1
Маршрут	OpenRouter / Novita; резервные маршруты отключены
Генерация	temperature = 0; top_p = 1; seed = 20260904
Дополнительные параметры запроса	fp8; reasoning.enabled = false; reasoning.exclude = true; require_parameters = true
Максимальный вывод	A0: 256 токенов; извлечение: 3072; выбор в B_ledger/A2: 1536
Контекст и инструменты	Полная собственная история; не более 1 запроса среды на точку; heartbeat = false
Ошибки и лимиты	1 повтор при ошибке валидации; 0 транспортных повторов; тайм-аут 120 с; запрос не более 48 000 байт

Сохранённые запросы подтверждают модель, параметры генерации, лимиты и маршрут; ответы сообщают DeepSeek V3.1 и Novita. Это не независимая проверка внутреннего исполнения всех параметров провайдером. Фактические вычисления не выровнены: у структурированных методов есть отдельное извлечение и более длинные ответы. Повторы после ошибок также входят в затраты.

4.2. Оценщик, ошибки и единица анализа

Агент получает публичный кадр: историю, наблюдения, меню, доступные каналы и результаты собственных действий. Эталонные идентификаторы и наборы due остаются на стороне среды и оценщика. Использован отдельный запуск, а не исходный путь PM-Bench с подстановкой due после неразобранного ответа. При повторной ошибке извлечения или выбора система не исполняет целевое действие и записывает отказ. Выбор A для продолжения текущей сцены не является выполнением отложенного поручения [6].

Проверка границы данных и сохранённых запросов поддерживает утверждение о разделении в этом запуске. Она не является универсальным доказательством отсутствия любых каналов утечки. В журнале сохраняются сырые запросы и ответы, повторы, действия до и после преобразования идентификаторов, оценки, токены, длительности вызовов и стоимость [7].

Набор due вычисляется по состоянию оценщика: актуальным задачам, времени, событиям, отменам и фактически состоявшимся завершениям. Это не список, который

агент считает готовым к исполнению. Для скрытого сигнала оценщик располагает состоянием среды независимо от того, запросил ли его агент. Незавершённый предшественник может не допустить зависимую задачу в due. Поэтому число обязательств, хотя бы раз требовавших исполнения, различается между методами даже при одинаковом исходном сценарии.

На траектории TP суммирует верные выборы в нужных точках, FP лишние выборы, FN пропущенные действия из due. Используются неизменённые правила Set-F1; это показатель согласованности наборов действий, а не обычная доля правильных ответов [1, 7].

$$Precision = TP / (TP + FP)$$

$$Recall = TP / (TP + FN)$$

$$Set-F1 = 2TP / (2TP + FP + FN)$$

Сначала Set-F1 вычисляется отдельно для каждой траектории. Основной показатель метода есть арифметическое среднее этих 12 значений: каждая траектория получает одинаковый вес. Основной контраст есть среднее 12 парных разностей A2 – B_ledger; дополнительный контраст A2 – A0 считается отдельно. Micro Set-F1 получают иначе: сначала складывают TP, FP и FN по всем траекториям, затем применяют формулу. Траектории с разными знаменателями оказывают на него разное влияние.

Если знаменатель нулевой, вспомогательный расчёт возвращает неопределённое значение, а не придуманную оценку. В этих 36 запусках знаменатели Set-F1 положительны. Интервалы, стандартные отклонения и проверки значимости не заявляются. Вызовы модели и контрольные точки не являются независимыми повторениями, а 12 траекторий связаны четырьмя общими шаблонами.

5. Результаты

5.1. Пилоты и проверка работоспособности

В первоначальном пилоте A0 и A1 получили Set-F1 = 1,00: TP = 5, FP = 0, FN = 0. В более длинной трёхдневной проверке оба условия получили TP = 11, FP = 0, FN = 1, то есть Set-F1 = 22/23 ≈ 0,9565. A1 использовал больше входных токенов. Эти два сравнения не показали улучшения; первый пилот имел потолок, оставлявший нулевой запас для роста показателя. Результат не означает, что инструкции бесполезны вообще [8].

История архитектурной разработки содержит неудачную проверку v2 с пустым хранилищем и последующую исправленную v2.1. В отдельном реальном smoke v2.1 завершены восемь точек и три намерения: TP = 3, FP = 0, FN = 0, Set-F1 = 1,00; зарегистрированы семь запросов и три успешных подтверждения. Это проверка работоспособности на известном сценарии, без сравнительного условия. Даже там сохранялись ошибки полей и их последующие исправления [9].

5.2. Основное сравнение

Таблица 3 содержит итоговые оценки. Значения среднего и micro различаются по определению, а не из-за округления. A0 имеет наибольшее среднее траекторное Set-F1. A2 уступает обоим более простым условиям [7].

Таблица 3. Качество в зафиксированном сравнении, 12 траекторий на метод.

Метод	TP	FP	FN	Micro Set-F1	Среднее траекторное Set-F1
A0	22	6	2	0,8462	0,8643
B_ledger	18	4	3	0,8372	0,8111
A2	12	5	7	0,6667	0,4806




Рисунок 2. Основной показатель: среднее Set-F1 по 12 траекториям. Шкала от 0 до 1; столбцы начинаются с нуля. Данные пересчитаны по сохранённым оценкам; неопределённость не оценивалась.

Основная парная разность A2 – B_ledger равна –0,330556 единицы F1; дополнительная A2 – A0 равна –0,383730. Шестизначные значения восстановлены из траекторных данных, а не вычитанием округлённых четырёхзначных чисел таблицы. Гипотеза улучшения не получила поддержки в этом сравнении. Это описательный вывод без утверждения о статистическом отклонении гипотезы.

Результаты неоднородны: среднее A2 в семействе cross_day равно 0,0000, а в visible_events равно 0,8667 при 0,8000 у B_ledger. Небольшое преимущество в visible_events наблюдалось без запросов инструментов и не доказывает пользу мониторинга. На пересекающемся со smoke сценарии v2_hidden_91320 A2 получил Set-F1 = 0 при уже непустом хранилище и шести запросах. Успешный прежний smoke не оказался гарантией повторного успеха. Исторические запуски не объединяются с итоговыми как дополнительные повторения [7, 9].

5.3. Ресурсы и учёт обязательств

Таблица 4. Фактическое использование модели и сообщённые API расходы.

Метод	Вызовы	Входные токены	Выходные токены	Стоимость, USD
A0	117	177 855	3 175	0,04047
B_ledger	251	910 740	44 534	0,21212
A2	234	843 540	42 889	0,19871

Метод	Вызовы	Входные токены	Выходные токены	Стоимость, USD
Всего	602	1 932 135	90 598	0,45130




Рисунок 3. Стоимость ответов API в данном эксперименте, USD. Столбцы начинаются с нуля. Это расходы зарегистрированного запуска, а не текущие тарифы или полный бюджет разработки.

По неокруглённым записям A2 стоил 0,19870816 USD, A0 0,04047361 USD; отношение равно 4,90957, то есть приблизительно 4,91. A0 сочетал наибольший основной показатель и наименьшую сообщённую стоимость. Суммарно API сообщил 0,45130261 USD. Независимая сверка с итоговым счётом провайдера отсутствует. Расходы включают извлечение, выбор и повторы после ошибок. Токены и стоимость не используются для вывода о задержке [7].

Таблица 5. Запросы, действия и подтверждения в итоговом сравнении.

Метод	Запросы скрытой панели	Успехи с поддержкой запроса	Исполнения	Успешные receipts	Ошибки валидации выбора
A0	15	6	28	22	2
B_ledger	8	4	22	18	24
A2	18	3	17	12	15

Успех с поддержкой запроса означает, что в той же точке имеется ответ соответствующего канала, согласованный с успешно выбранным скрытым действием. Это наблюдаемая опора, а не доказательство внутренней причинной роли запроса. Несколько действий могут опираться на один ответ. Ошибки валидации выбора считаются по попыткам, включая повторные. Их нельзя делить на все вызовы модели: последние включают и извлечение, а знаменатель попыток выбора в краткой таблице не приведён.

Таблица 6. Учёт исходных обязательств по состоянию оценщика.

Метод	Поручено	Хотя бы раз due	Блокировались зависимостью	Завершено	Не завершено без отменённых	Отменено
A0	27	24	0	22	2	3
B_ledger	27	21	3	18	6	3
A2	27	19	5	12	12	3

Три отмены в семействе revision объясняют первоначально неясный остаток: для каждого метода завершённые + незавершённые без отменённых + отменённые = 27. Число блокировок A0, отсутствовавшее в краткой сводке, повторно вычислено по журналам и равно нулю. Это измеренное значение, а не подстановка вместо пропуска. Блокировка фиксируется при наличии триггера и незавершённого предшественника [7].

У A2 пять зависимых обязательств не стали due: два в hidden и три в cross_day. Поэтому 12 незавершённых не равны семи официальным FN. Снижение числа due вследствие ранних неудач не является улучшением. Таблица обязательств дополняет неизменённую метрику и делает такие последствия видимыми.

6. Анализ ошибок и обсуждение

6.1. Наблюдаемые стадии отказа

Послезапусковой семантический разбор охватил 24 случая структурированных методов; отдельно просмотрены 12 поведенческих траекторий A0. Разбор выполнен с помощью ИИ, без независимого человека-разметчика. Для статьи ключевые примеры сверены с сырыми ответами, снимками хранилища и receipts. Таблица 7 показывает симптомы и наиболее раннюю подтверждённую стадию, но не приписывает каждой категории частоту и не предполагает их взаимоисключения [7, 10].

Таблица 7. Сбои зафиксированного сравнения и границы их интерпретации.

Симптом	Ранняя подтверждённая стадия	Последствие	Альтернативное объяснение / предел	Доказательство
Нет записи к нужному сроку	Применение извлечения: пакет отклонён из-за ссылки на зависимость	Пропущена регистрация	В черновике действия названы; это не доказательство отсутствия понимания	A2 hidden_91320, точки 1–3
Пропущен предшественник	Принятое извлечение без зависимости	Меняется допуск; позднее задача может остаться заблокированной	Причины пропуска и роль инструкции отдельно не изолированы	A2 hidden_91320, точки 3–4
Возвращается старый срок	Принятая новая версия записи	Преждевременно действие и неуспешный receipt	Ошибка пересмотра сочетается с ошибкой выбора	A2 revision_91300, точки 4–7
Верный будущий день, действие сегодня	Выбор и привязка к неверному пункту меню	Ложное действие; нужная регистрация не завершена	Правильное хранение не устраняет ошибку выбора	A2 cross_day_91331, точка 3
Положительный ответ панели без исполнения	Валидация выбора после запроса	Пустой набор целевых действий	Недостаточная частота запросов не объясняет этот шаг	A2 hidden_91320, точка 7
Возврат прежнего событийного сигнала	Принятый пересмотр условия	Преждевременно запечатывание	Позднее исправление может скрыть дефект в высоком F1	A2 visible_events_91310; B_ledger, семейство visible_events

Обозначения случаев в таблице сокращены: перед именем каждого сценария стоит префикс v2_. Для первых пяти строк доступны непосредственные журналы и проверка их

соответствия описанию; последняя строка опирается на сохранённую ИИ-аннотацию с указателями на ответы. Полные пути и номера строк вынесены в записку проверки. Ошибки ранней v2 с несогласованным контрактом извлечения отделены от этой таблицы. Их исправление предшествует итоговому запуску, поэтому ими нельзя без дополнительного доказательства объяснить весь итоговый дефицит.

6.2. Разбор цепочки и возможное объяснение

В A2 на v2_hidden_91320 первые две точки завершились отклонением пакетов извлечения и пустым хранилищем. В третьей точке намерения появились, но срок регистрации уже прошёл. Зависимость запечатывания сначала отсутствовала, затем была восстановлена. На седьмой точке запрос board_cobalt91320 дал положительное наблюдение; выбор и разрешённый повтор не прошли проверку, целевых действий и receipts не было. Скрытое свидетельство было получено, но цепочка не завершилась [7, 10].

В v2_revision_91300 A2 повторно вернул срок 12:00 после переноса на 13:00. На шестой точке он выполнил преждевременный выбор и получил simulator_not_completed; на седьмой восстановил 13:00 и получил simulator_completed. Все 16 ответов модели в этом случае прошли валидацию. Значит, корректный формат и допустимые ссылки не гарантировали правильный смысл изменения [7, 10].

В v2_cross_day_91331 в записи сохранён DayTwo, однако на третьей точке DayOne выбран отвлекающий пункт меню для запасного образца и связан с настоящим намерением регистрации. Receipt был неуспешным, а регистрация позднее не завершилась. Это показывает отдельный сбой выбора и привязки при правильном поле дня. Утверждать, что все проблемы вызваны извлечением, на основании такого случая нельзя [7, 10].

Есть и работающая цепочка: в A2 на v2_hidden_91322 после исправления зависимости и повтора выбора регистрация завершилась. На седьмой точке положительный ответ панели использован при выборе запечатывания и архивирования; оба действия получили успешные receipts. Итоговый Set-F1 = 1,00 сосуществует с промежуточными ошибками. A0 на том же сценарии тоже завершил три задачи, используя меньше запросов и вызовов. Этот пример показывает реализуемость цепочки, но не её преимущество [7, 10].

Совокупность наблюдений согласуется с возможным распространением смысловых ошибок через промежуточные представления: неверное поле влияет на допуск или привязку, затем неудача предшественника ограничивает последующие обязательства. Однако это кандидатное объяснение. Здесь не проведено вмешательство, отделяющее вклад извлечения, инструкции, контроллера, валидации и модели. Общая структура B_ledger и A2 сама по себе не объясняет разность между ними. Кроме того, B_ledger имеет больше ошибок валидации выбора, 24 против 15, но более высокий F1. Простое число отказов не объясняет ранжирование.

7. Ограничения, практическая значимость и вклад автора

Оценена одна конфигурация DeepSeek V3.1 и один запуск каждой пары «метод–траектория». Четыре семейства и три варианта каждого ограничивают независимость наблюдений. Сценарии были доступны при разработке; один использовался в smoke-проверках. Эти условия не являются скрытой тестовой выборкой. Фиксированные seed и

temperature не заменяют повторения и не гарантируют воспроизводимость ответов удалённого сервиса.

Вычисления между условиями не выровнены. A0 и структурированные методы имеют разные инструкции, число этапов и лимиты вывода; B_ledger и A2 после запросов видят разные собственные истории. Поэтому сравнение A2/A0 относится к целым системам, а A2/B_ledger к двум политикам внутри общего каркаса. Оно не выделяет универсальный причинный эффект «добавленной памяти».

Семантические аннотации подготовлены с помощью ИИ, без независимого разметчика и измерения согласия экспертов. Отдельные описания допускают альтернативные объяснения. Расходы подтверждены ответами API, но не независимым счётом. Выполнение провайдером всех запрошенных параметров не проверено напрямую. Доступность полных журналов позволяет повторить оценивание, но не обещает идентичную новую генерацию.

Проверялась англоязычная симуляторная среда. Русская статья и казахская аннотация не являются многоязычным экспериментом. Реальное фоновое наблюдение, внешние побочные эффекты, часовые пояса и пользовательская полезность не оценены. Удаление завершённых пунктов самим PM-Bench также не позволяет независимо измерить предотвращение повторных внешних действий.

Потенциальное применение состоит в оценке помощников, которые следят за расписанием, обновляют поручения и реагируют на появление материалов. Предложенная организация журналов помогает различать пропуск, неверное условие, неправильное действие и неуспешное исполнение. Повышение успеваемости, экономия времени пользователей и надёжность внедрения остаются непроверенными возможностями.

Авторская часть проекта включает постановку вопроса о перспективной памяти и определение контролируемого сравнения, отражённые в исходной рукописи и последовательных постановках работы. Программирование, анализ записей и подготовка текста выполнялись с помощью ИИ-инструментов, включая Codex. Не заявляется самостоятельное написание каждой строки кода или независимая человеческая разметка. PM-Bench и его оценщик принадлежат исходным авторам; архитектурные идеи соотнесены с PIS и другими работами. Степень личного освоения результатов должна быть подтверждена дневником исследования и устной защитой, а не самим фактом наличия репозитория.

8. Заключение

В проекте исследована перспективная память языковых ИИ-агентов: выполнение актуального намерения при нужном времени или событии с учётом изменений, зависимостей и результата исполнения. Работа прошла от инструкции P1 к структурированному хранилищу и программному мониторингу. В пилотах A0/A1 улучшения не наблюдалось; отдельный успешный smoke показал работоспособность цепочки в известном сценарии.

В зафиксированном сравнении на 12 траекториях четырёх семейств среднее Set-F1 составило 0,8643 у A0, 0,8111 у B_ledger и 0,4806 у A2. Основная разность A2 – B_ledger равна $-0,330556$, дополнительная A2 – A0 равна $-0,383730$. A0 имел наименьшую сообщённую API стоимость. Гипотеза улучшения не получила поддержки в этом сравнении. Результат ограничен одной конфигурацией модели, доступными при разработке сценариями и отсутствием повторений; он не доказывает общую бесполезность структурированной памяти.

Сохранённые записи показывают ошибки пересмотра намерений, привязки и выбора, в том числе после получения нужного свидетельства. Смысловое распространение ошибок остаётся возможным объяснением, а не установленной причиной всего дефицита. Учёт отмен и зависимостей необходим вместе с Set-F1, поскольку не каждое незавершённое обязательство становится официальным пропуском.

Один следующий диагностический опыт мог бы заменить модельное извлечение и пересмотр эталонной разметкой только уже раскрытой информации, сохранив последующие этапы системы. Такая разметка не должна включать будущие события, скрытые ответы или неслучившиеся завершения. Этот опыт не выполнен. Он помог бы локализовать роль формирования записей, но не был бы готовым продуктом, автоматической верхней границей качества или доказательством единственного узкого места.

9. Список использованных источников

Внешние научные источники

- [1] Liu G., Gabriel S. PM-Bench: Evaluating Prospective Memory in LLM Agents. arXiv:2607.12385v1, 14.07.2026. URL: <https://arxiv.org/abs/2607.12385v1>.
- [2] Rendell P. G., Craik F. I. M. Virtual week and actual week: Age-related differences in prospective memory. *Applied Cognitive Psychology*. 2000. Vol. 14, No. 7. P. S43–S62. DOI: 10.1002/acp.770. URL: <https://onlinelibrary.wiley.com/doi/10.1002/acp.770>.
- [3] Zhang T., Wang X., Zhang Q., Chen Q., Li K., Chen Y., Wang D., Meng H., Lu Y. TriggerBench: Investigating Prospective Memory for Large Language Models. arXiv:2606.23459v1, 22.06.2026. URL: <https://arxiv.org/abs/2606.23459v1>.
- [4] Hu Y., Wang Y., McAuley J. Evaluating Memory in LLM Agents via Incremental Multi-Turn Interactions. arXiv:2507.05257. Первоначально 2025; использована v4 от 28.06.2026. URL: <https://arxiv.org/abs/2507.05257v4>.
- [5] Zhao J., Wu C. Making Prospective Memory SLM-Shaped: Typed Intention Stores for Small-Model Agents. arXiv:2609.01272v1, 01.09.2026. URL: <https://arxiv.org/abs/2609.01272v1>.

Внутренние материалы проекта Kiodai

- [6] Kiodai. Зафиксированный протокол и реализация v2.1-comparison-v1. 10–11.09.2026. `research/v2_1/comparison_v1.json`; `configs/v21_comparison_v1.json`; `kiodai_v2/agent.py`, `store.py`; `prompts/v2_1/`. Версии указаны в разделе 4.1.
- [7] Kiodai. Первичные записи и итоговые оценки v2.1-comparison-v1. 11.09.2026. `results/v2_1/comparison-v1/`: `scenario.json`, `calls.jsonl`, `actions.jsonl`, `steps.jsonl`, `score.json` в 36 каталогах; `comparison_report_reviewed.json`. Инвентарь: `research/v2_1/live_comparison_v1_inventory.json`.
- [8] Kiodai. Историческая рукопись; `RESULTS.json`, `FOLLOWUP_RESULTS.md` и `FOLLOWUP_RESULTS.json`; записи `live-pair-42433e00474b` и `live-pair-bdf241965f35`. Пилоты A0/A1, 08–09.09.2026.
- [9] Kiodai. Разработка v2 и отдельный smoke v2.1. `docs/v2/DEEPSEEK_SMOKE_RESULTS.md`; `docs/v2_1/DEEPSEEK_SMOKE_RESULTS.md`; `results/v2_1/deepseek-smoke-v1/analysis.json`. 09.09.2026.
- [10] Kiodai. Послезапусковой разбор ошибок. `results/v2_1/comparison-v1/semantic_review.json`, `baseline_behavior_review.json`; `docs/v2_1/COMPARISON_RESULTS.md`. 11.09.2026. ИИ-аннотации; ключевые случаи сверены с исходными журналами.

Дата проверки внешних записей и локальных материалов: 12.09.2026. Полные указатели, хеши, данные рисунков и результаты повторного расчёта включены в отдельные материалы проверки.