

Kiodai — записка об источниках и проверке

Документ сопровождает исследовательскую статью Беймжана Багдата, подготовленную 12 сентября 2026 года. Он отделяет проверенные записи от авторских сведений, интерпретаций и невыполненных предложений. Новые обращения к оцениваемой модели не выполнялись; исходные результаты, сценарии, инструкции и правила оценивания не изменялись.

1. Источники и их доказательная роль

Исходная рукопись: `/Users/bagnesium/Downloads/Kiodai_Bagdat_Beimzhan.docx`. Она подтверждает исходную тему, титульные сведения, трёхязычную структуру и план A0/A1. Сообщения о том, что реальные эксперименты ещё не состоялись, устарели. Рукопись не использована как свидетельство завершённого архитектурного исследования.

Правила: `/Users/bagnesium/Downloads/Telegram Desktop/1_Правила_оформления_научных_проектов_для_учащихся_—_копия_1.docx`. Документ требует титульный лист, оглавление, три аннотации не более 250 слов, введение не более двух страниц, исследовательскую часть не более 20 страниц, заключение не более одной страницы и последовательные ссылки в квадратных скобках. Дополнительно названы отзыв руководителя и проверка Turnitin. Шрифт, поля и интервал в доступном документе не заданы.

Итоговая сводка: числовые таблицы из задания автора и `docs/v2_1/COMPARISON_RESULTS.md`. Краткая авторская сводка проверена по соответствующим первичным записям `results/v2_1/comparison-v1/`. Файл `reports/FINAL_RESULTS.md` с фразой об отсутствии финальных экспериментов и заготовка `paper/main.md` устарели. Они сохранены без перезаписи. Поздняя запись `Completed frozen v2.1 comparison` в `research/CLAIMS.md` соответствует завершённому запуску; более ранние отрицательные и подготовительные записи остаются историческими.

Достоверность первичных чисел проверялась по `score.jsonl`, `actions.jsonl`, `calls.jsonl`, `steps.jsonl`, `scenario.json` и манифестам. Семантические объяснения проверялись отдельно: опубликованный внутри проекта разбор является ИИ-аннотацией, а не независимой человеческой оценкой. Предыдущие сообщения помощников не использованы как отдельное доказательство.

В `research/v2/source_inventory.json` перечислены семь ранее предоставленных PDF. В доступных сейчас каталогах проекта, приложений и `Downloads` соответствующие PDF не найдены. Поэтому прежняя запись об их чтении не выдана за нынешнюю проверку. Для центральных ссылок проверены оригинальные страницы arXiv и тексты PM-Bench, TriggerBench и PIS; для MemoryAgentBench проверена запись arXiv v4, для Virtual Week — страница издателя Wiley. Остальные перечисленные ранее статьи не используются для центральных утверждений и не включены в библиографию ради объёма.

2. Версии и границы повторной проверки

Зафиксированный кандидат: `959db38dac8b68f63ecf79420dcd53bea2278cf2`. Поддержка сравнения: `832d6ff1e3f43f9086da9d6aac33b79f5212ecdc`. Коммит фактического запуска: `cd0ce89e10d036918d1af06e5f5f2140930a0981`. SHA-256 манифеста

research/v2_1/comparison_v1.json:
bfaf52df48553e35978f39f406fd5eb3d78c918a5ac2713a0a169746f23036d5.

Проверено совпадение 59 зафиксированных файлов, 445 исходных файлов запуска, 442 подготовительных и 65 записей происхождения. Проверен архив artifacts/v2_1/comparison_v1_original_run.zip; SHA-256: 942fb127adb110c69ec8a0a74d6100cca2059b13c91cd450b190fd0b19931499. Сопоставлены с git show коммита запуска Agent, Store, runner, report, исходный оценщик, вспомогательный отчёт и три используемых файла инструкций. Их текущие байты совпали с оценённой версией. Это позволило повторно оценить сохранённые действия без подмены реализации более новой.

Официальный score_log повторно применён ко всем 36 полным траекториям. Результат полностью совпал с сохранёнными score.json. Повторное воспроизведение состояния оценщика совпало с due на каждой из 288 точек. Проверена конфигурация всех 602 сохранённых запросов и соответствие ответов заявленным DeepSeek V3.1 / Novita. Это проверка записей API, а не независимое доказательство серверного исполнения каждого параметра.

Исторические пилоты остаются отдельными. Их первичные артефакты и оценки перечислены в historical_audit.json. Проверка v2.1 smoke отделена от итогового сравнения и не засчитывается как его повторение. Неудачный более ранний v2 smoke не скрыт. Во время подготовки статьи выполнены только локальные проверки и воспроизведение уже сохранённых действий; новый МОСК-smoke размещён во временном каталоге, а не поверх первичных данных.

3. Числа, расчёты и исправленные неоднозначности

Таблицы статьи и рисунки согласованы с data/audit_results.json, data/method_summary.csv и data/trajectory_scores.csv. В последнем файле 36 строк с реально сохранёнными траекторными значениями, а не восстановлением по агрегатам. Среднее траекторное Set-F1: $A0 = 0,8642857142857143$; $B_ledger = 0,8111111111111112$; $A2 = 0,4805555555555557$. Основная средняя парная разность равна $-0,3305555555555555$; дополнительная $-0,3837301587301587$. Округления до шести знаков в статье корректны.

Micro Set-F1 по объединённым счётчикам: $A0 = 44/(44+6+2) = 0,8461538462$; $B_ledger = 36/(36+4+3) = 0,8372093023$; $A2 = 24/(24+5+7) = 0,6666666667$. Эти величины не заменяют среднее по траекториям. Ни 1 – F1, ни процент относительного ухудшения не выдаются за измеренную частоту ошибок.

Суммы вызовов $117+251+234 = 602$, входных токенов $177855+910740+843540 = 1932135$, выходных $3175+44534+42889 = 90598$. Стоимости из ответов: $0,04047361 + 0,21212084 + 0,19870816 = 0,45130261$ USD. Отношение $A2/A0 = 0,19870816 / 0,04047361 = 4,9095734233$. Используются сохранённые расходы запуска, а не текущие тарифы, резервы бюджета или все расходы проекта. Независимый итоговый счёт не предоставлен. Задержка не выведена из стоимости или токенов; временные поля остаются в исходных журналах.

Разница между 27 поручениями и 24 завершёнными либо активными незавершёнными объясняется тремя настоящими отменами в сценариях revision. Балансы: $A0\ 22+2+3=27$; $B_ledger\ 18+6+3=27$; $A2\ 12+12+3=27$. Это решённая, а не оставленная неопределённость.

В краткой сводке для A0 отсутствовало число блокировок; оно заново вычислено как 0 и явно помечено в статье как результат аудита. Сохранённые ошибочные отмены внутри хранилища агента не считаются официальными отменами оценщика.

Due определяется состоянием среды и фактическими завершениями при воспроизведении, а не намерениями в SQLite агента. Блокировка зависимостью фиксируется, когда триггер наступил, а предшественник не завершён. Поэтому A2 имеет 19 хотя бы раз due, семь официальных FN и 12 незавершённых без отменённых. Пять зависимых задач, не ставших due, не добавлены к официальным FN. Расчёт не меняет правила оценивания.

B_ledger и A2 имеют общие версии, отмены, зависимости и receipts. Их различие в контроле запросов подтверждено Agent.decide и Store.monitor. В таблице методов эти механизмы не приписаны исключительно A2. Допуск Store.eligible проверяет текущую версию, статус и завершение зависимостей, но не исчерпывающее семантическое соответствие действия дню, времени и условию. Это существенно для интерпретации ошибки при правильном поле when.

4. Точные указатели на разбор ошибок

Пути ниже начинаются с results/v2_1/comparison-v1/. Номера строк считаются с единицы; контрольная точка не равна номеру строки calls.jsonl. Читатель может проследить соответствующий запрос, ответ, снимок и исполнение. Таблица ошибок статьи не содержит придуманных частот и не является классификацией независимых испытаний.

A2, v2_hidden_91320: calls.jsonl, строки 2, 4, 6, 8 показывают отклонённые первые пакеты; steps.jsonl, строки 1–2 подтверждают пустое хранилище и отсутствие действий, строки 3–4 — появление записей и исправление зависимости. Строка 7 steps.jsonl содержит положительный ответ board_cobalt91320 и fail_closed без целевых действий. Семантическая аннотация указывает, что черновики уже называли поручения; отсутствие записи нельзя автоматически объявлять отсутствием языкового распознавания.

A2, v2_revision_91300: calls.jsonl, строки 22, 24, 26, 28; steps.jsonl, строки 6–7. Срок сначала возвращён к 12:00, исполнение неуспешно; после восстановления 13:00 успешное завершение. Все 16 ответов имеют пустое поле validation_error. Это непосредственно проверенный пример принятой смысловой ошибки.

A2, v2_cross_day_91331: calls.jsonl, строки 16 и 18; steps.jsonl, строка 3; intention i_c80cc5936d3d44ab содержит when = DayTwo 11:00. Выбран task_5 в DayOne; действие отображается в отвлекающий пункт, receipt = simulator_not_completed. На строке 7 steps.jsonl регистрация не выполнена. Статья не утверждает, что статус failed сам по себе делает любой повтор невозможным: механика допуска и последующие решения различаются.

A2, v2_hidden_91322: calls.jsonl, строки 2, 6, 8, 10 и 32; steps.jsonl, строки 1–7. Подтверждены исправление зависимости, повтор выбора регистрации, положительный запрос в точке 7 и два успешных receipts. Сравнение с A0 подтверждает по три успешных действия при меньших ресурсах A0 в этом блоке. Это пример интеграции, а не свидетельство общего превосходства.

Строка о восстановлении прежнего событийного сигнала в таблице 7 опирается на semantic_review.json: A2 v2_visible_events_91310 и все три B_ledger visible_events. Она обозначена как источник с ИИ-аннотацией; всесторонняя независимая семантическая

переразметка всех 24 случаев в этой редакторской работе не заявляется. Прилагаемый `source_claims.csv` сохраняет отдельные статусы доказательств.

5. Проверка внешних источников

PM-Bench: Genglin Liu, Saadia Gabriel; arXiv:2607.12385v1 от 14.07.2026. Проверены оригинальные запись и PDF; использованы постановка, взаимодействие и существующий todo-ledger. Ссылка: <https://arxiv.org/abs/2607.12385v1>.

Virtual Week: Peter G. Rendell, Fergus I. M. Craik; Applied Cognitive Psychology, том 14, выпуск 7, S43–S62, 2000; DOI 10.1002/acp.770. Wiley отдельно указывает первое онлайн-размещение 29.03.2001. В библиографии сохранён год выпуска 2000; он не заменён датой онлайн-размещения. Полный текст не использован для неподтверждённых подробностей процедур. Ссылка: <https://onlinelibrary.wiley.com/doi/10.1002/acp.770>.

TriggerBench: Tianhua Zhang, Xinjiang Wang, Qianxi Zhang, Qi Chen, Kun Li, Yaoqi Chen, Dingdong Wang, Helen Meng, Yan Lu; arXiv:2606.23459v1 от 22.06.2026. Проверены запись и оригинальный HTML, включая matched RM, положительные, отрицательные и перегруженные варианты. Ссылка: <https://arxiv.org/abs/2606.23459v1>.

MemoryAgentBench: Yuanzhe Hu, Yu Wang, Julian McAuley; Evaluating Memory in LLM Agents via Incremental Multi-Turn Interactions, arXiv:2507.05257. Исходная дата 07.07.2025, использована запись v4 от 28.06.2026. Это не статья MemBench с идентификатором 2506.21605. Утверждение о четырёх способностях подтверждено оригинальной аннотацией. Ссылка: <https://arxiv.org/abs/2507.05257v4>.

PIS: Jinqing Zhao, Chengcan Wu; Making Prospective Memory SLM-Shaped: Typed Intention Stores for Small-Model Agents, arXiv:2609.01272v1 от 01.09.2026. Прочитано описание Form, Revise, Filter, Decide. Новизна хранилища не приписана Kiodai. Числа PIS не используются как сопоставимый контроль; точное воспроизведение отсутствует. Ссылка: <https://arxiv.org/abs/2609.01272v1>.

6. Оформление и комплект воспроизводимости

Редакторский выбор: A4; поля слева 25 мм, остальные 20 мм; Times New Roman 12 пт для основного текста; умеренный межстрочный интервал; таблицы и подписи компактнее основного текста, без уменьшения исследовательского содержания ради заданного числа страниц. Эти параметры не названы обязательными правилами конкурса. Зарегистрированное название, направление, секция, школа, автор, класс и руководитель сохранены. Дедлайн 13.09.2026 является сведением автора, а не независимо подтверждённым организатором сроком.

Оглавление формируется по всем нумерованным заголовкам и трём аннотациям с проверенными по PDF номерами страниц и ссылками на разделы. Оно статическое: после существенного редактирования в Word требуется обновить его по новой вёрстке либо заново выполнить сборку. Текущие номера проверены в окончательном PDF. Таблицы и формулы редактируются в DOCX. Графики построены из CSV с нулевой базой; у F1 шкала 0–1, интервалы неопределённости не добавлены. SVG и код построения редактируемы.

Скрипт `source/audit_evidence.py` пересчитывает данные без сетевых вызовов и изменений результатов. `source/build_documents.py` собирает документы из Markdown; `source/figures.py` строит рисунки через ReportLab. В supplement включены фактически

существующие инструкции, конфигурация, схема и манифесты с исходными именами. Динамические полные запросы и их схемы остаются в calls.jsonl первичного архива; статические шаблоны не выдаются за каждый полный запрос.

7. Нерешённые вопросы и действия перед сдачей

В доступном комплекте нет подписанного отзыва руководителя. По предоставленным правилам он должен отражать актуальность, личный вклад, недостатки и рекомендации по использованию результатов. Подпись, одобрение руководителя и независимая валидация не выдуманы.

Нет отчёта Turnitin. Его наличие и допустимый порядок подачи должен проверить автор со школой. Текстовая сверка и ссылки в статье не заменяют такую проверку. Если школа требует отдельный дневник, анкету, подписи или стенд, эти материалы не следует считать созданными данным комплектом. Стенд в присланных правилах рекомендован, отзыв указан как сопровождающий каждую работу.

Автору необходимо подтвердить описание личного вклада и понимать цепочки, таблицы и ограничения на защите. Точный вклад человека в отдельные коммиты нельзя установить только по имени автора git-коммита или по наличию итоговой рукописи. ИИ-помощь раскрыта. Казахская аннотация не прошла независимую проверку преподавателем; языковая вычитка желательна, но не выдана за выполненную.

Остаются научные ограничения: нет независимой человеческой переразметки, независимого биллинга, скрытой выборки, дополнительных повторений и прямой проверки всех серверных параметров. Они не мешают описать полученный результат, но ограничивают возможные утверждения. Диагностический опыт с эталонным извлечением только раскрытой информации не выполнен. Никакое новое платное исследование не запущено и не требуется для завершения этой редакции.